

Predição e Inteligência Analítica para Alfabetização no Brasil

Reunião executiva — um radar de risco antecipado para gestores públicos, construído sobre dados **reais** de 5.516 municípios brasileiros (Base dos Dados / CNCA).

Raphael Reis

Hoje só sabemos quem foi alfabetizado depois que o resultado sai.

E se pudéssemos antecipar esse diagnóstico — ainda durante o ano letivo — e agir antes do resultado final, não depois?

O RETRATO DE 2024 — DADOS REAIS, BASE DOS DADOS / CNCA

5.516

municípios brasileiros
avaliados

53,3%

atingiram sua meta de
alfabetização

46,7%


ficaram abaixo da própria
meta

Quase metade dos municípios do Brasil não atingiu sua meta em 2024 — mas isso só se sabe depois que o resultado sai.

46,7% dos municípios não atingiram a meta. E hoje, só descobrimos isso depois.

Gestores precisam de um jeito de enxergar risco **antes** do próximo resultado — para direcionar apoio pedagógico enquanto ainda há tempo de agir, não só de registrar o que já aconteceu.

Um modelo que aprende com o histórico de cada município para estimar o risco antes do resultado sair



Pré-processamento e modelo vivem em um **pipeline único e reproduzível** — nenhuma decisão é manual ou específica de uma planilha.

Dois cuidados que separam um modelo confiável de uma ilusão estatística

Vazamento acontece quando o modelo, sem querer, tem acesso a informação que só existiria *depois* do resultado — e passa a "colar" em vez de prever de verdade.

VAZAMENTO DE DADOS

O indicador "sabia" a própria resposta

Saber se um município atingiu a meta em 2024 já exige comparar o resultado de 2024 com a meta de 2024 — usar o resultado do próprio ano como variável seria prever o presente com o presente.

Correção: modelo usa apenas o histórico de 2023 e a meta vigente.

CORREÇÃO DE ROTA


Trocamos os dados no meio do caminho

A primeira versão usava uma amostra sintética de teste. Um número implausível nos fez investigar, confirmar que era um artefato da amostra, e voltar à base real da Fase 2.

O que vocês vêo hoje são dados reais de 5.516 municípios.

Confiança em ciência de dados vem de auditar o próprio trabalho, não só de acertar a métrica.

Três abordagens testadas, uma vencedora




Com dados reais, o sinal é forte e consistente.

O desempenho se mantém estável entre a validação cruzada e o teste em municípios nunca vistos — sinal de que não há sorte nem "decoreba" envolvida.

Isso confirma que histórico municipal, histórico estadual e a meta vigente carregam sinal real sobre o resultado — muito acima do que a amostra sintética anterior permitia enxergar.

O que mais explica a alfabetização de um município



O estado de origem pesa mais do que qualquer outro fator isolado.

O modelo aprendeu que municípios de certos estados — RS, MG, BA — têm um padrão sistemático na relação entre desempenho e meta.

Isso não significa que "ser do RS" causa o resultado — significa que o estado concentra um padrão real que vale a pena entender a fundo. É o que fazemos a seguir.

O paradoxo do Sul: desempenho mediano, meta desproporcional

RIO GRANDE DO SUL Meta desproporcional Desempenho 2023 53,8% Meta 2024 71,4% Apenas 10,5% dos municípios atingem a meta	BAHIA Desempenho baixo de fato Desempenho 2023 36,6% Meta 2024 43,7% Apenas 18,9% dos municípios atingem a meta	CEARÁ Referência nacional Desempenho 2023 90,3% Meta 2024 78,9% 91,8% dos municípios atingem a meta
--	--	--

Uma mesma métrica — "taxa de municípios que atingiram a meta" — esconde dois problemas completamente diferentes.

O Rio Grande do Sul não tem o pior desempenho absoluto do Brasil — mas recebeu uma meta muito acima da sua trajetória recente, e por isso lidera o ranking de *risco relativo*. A Bahia tem um problema estrutural real de desempenho. O Ceará mostra que desempenho alto e meta ambiciosa podem coexistir — referência nacional que inspirou o próprio Compromisso Nacional Criança Alfabetizada. Tratar os três casos com a mesma política seria um erro.

Um ranking de risco por município, atualizável a cada ciclo

MENOR PROBABILIDADE ESTIMADA DE ATINGIR A META — 2024

Ajuricaba (RS)		4,1%
Espumoso (RS)		4,1%
Lagoão (RS)		4,1%
Ijuí (RS)		4,2%
Pinheirinho do Vale (RS)		4,4%

1.585 municípios em alto risco · 1.722 em risco moderado · 2.209 em baixo risco. Os 15 primeiros do ranking são todos do RS — reflexo do peso que o modelo dá à UF (ver limitações).

Priorizar antes do resultado sair, não depois.

Com esse ranking, a secretaria pode direcionar visitas técnicas, reforço pedagógico e material didático para os municípios de maior risco relativo **durante** o ciclo de avaliação.

O ranking já é útil para comparar **estados** entre si; para diferenciar risco dentro de um mesmo estado com mais precisão, precisamos de mais variáveis (Seção de limitações).

Quatro perfis de município, quatro estratégias diferentes

Agrupamento por padrão histórico e distância da meta (4.919 municípios com histórico completo, K-Means).

REFERÊNCIA · 1.384 MUNICÍPIOS

Meta alta e superada

Desempenho 2023: 83,7% · meta 2024: 78,3% · já acima da meta.

CONSISTENTE · 1.496 MUNICÍPIOS

Desempenho e meta compatíveis

Desempenho 2023: 65,0% · meta 2024: 67,0% · muito perto de atingir.

MODERADO · 1.136 MUNICÍPIOS

Desempenho e meta medianos

Desempenho 2023: 48,5% · meta 2024: 53,5% · gap moderado a fechar.

PRIORITÁRIO · 903 MUNICÍPIOS

Desempenho baixo

Desempenho 2023: 32,3% · meta 2024: 38,8% · precisa de investimento estrutural.

Uma política única para 5.516 municípios não funciona — agrupar por padrão permite estratégias sob medida para cada grupo.

O que este modelo ainda não sabe



Granularidade municipal, não individual

A tabela real de alunos só existe no BigQuery da equipe da Fase 2 — o modelo prevê o resultado agregado do município, não de um aluno específico.



Um único ano-alvo disponível

Só 2024 tem meta e resultado completos; 2023 serve apenas como histórico defasado — ainda não dá para aprender tendências de médio prazo por município.



Faltam variáveis socioeconômicas

Renda, IDH, infraestrutura escolar e formação docente ainda não estão na base.



Dependência forte da identidade da UF

O modelo campeão se apoia fortemente em "de qual estado o município é" — ótimo para comparar estados, mas ainda pouco preciso para diferenciar risco dentro de um mesmo estado.

Reconhecer os limites agora é o que evita decisões erradas depois.

Um modelo de política pública que esconde suas limitações é mais perigoso do que um modelo simples e honesto sobre o que ainda não sabe.

De um radar real a um piloto validado em campo

1

Chegar ao nível do aluno

Obter acesso à tabela real de alunos no BigQuery da Fase 2, mantendo o mesmo pipeline.

2

Enriquecer com dados reais

Censo Escolar, PNAD, IBGE — para diferenciar risco dentro de um mesmo estado.

3

Investigar a política de metas

Entender, junto ao CNCA, por que estados como o RS recebem metas tão acima do seu histórico recente.

Obrigado. Ficamos à disposição para aprofundar qualquer um desses pontos.